

● Production · 사내 운영 중

# 사내 지식 기반 RAG AI 어시스턴트 설계부터 운영까지 풀스택 단독 개발

PostgreSQL · pgvector 하이브리드 검색과 Cross-encoder 리랭킹, 멀티모달 문서 처리 (PDF·PPTX·Notion)를 결합해 5개 업종 사내 지식을 답변하는 RAG 챗봇. 검색·생성 파이프라인부터 관리자 콘솔, 사용자 분석, 배포·운영까지 직접 구현했습니다.

## 5개 업종

약국·병의원·학원·한의원·공  
통

## 하이브리드

벡터 + 키워드 + 구문 + 리  
랭커

## 멀티모달

PDF 비전 · PPTX · Notion

## End-to-

## End

검색·생성·관리자·분석·배포

## OVERVIEW

## 한눈에 보는 프로젝트

사내 직원이 업종별 매뉴얼·운영 지식을 자연어로 질문하면, 근거 문서를 검색해 출처와 함께 답변하는 사내 전용 AI 어시스턴트입니다. "그렇듯하지만 틀린 답변"을 막기 위해 **근거 기반 응답·관련 문서 노출·미답변 추적**을 핵심 원칙으로 설계했고, 실제 운영을 위한 관리자 콘솔과 사용자 분석까지 하나의 시스템으로 구축했습니다.



### 역할

기획·아키텍처·백엔드·프론트엔드·DB·배포까지 **단독 풀스택 개발**. RAG 파이프라인 설계와 검색 품질·응답속도 최적화를 주도.



## 문제

분산된 업종별 매뉴얼(PDF·PPT·Notion)을 직원이 빠르게 찾기 어려움. 일반 LLM은 사내 사실을 모르고 환각 위험.



## 해결

사내 문서를 벡터화한 하이브리드 RAG + 리랭킹으로 근거 기반 답변. 출처 링크·관련 화면을 함께 제공.

## FEATURES

# 핵심 기능



**하이브리드 검색 + 리랭킹** — pgvector 임베딩 검색 · 키워드(tsvector) · 구문 매칭 점수를 결합하고, bge-reranker Cross-encoder로 재정렬해 정확도 향상.



**LangGraph 대화 파이프라인** — 질문 분류 → 멀티턴 맥락 기반 질의 재작성("그거/아까" 해소) → 검색 → 근거 기반 프롬프트 생성을 그래프로 구성.



**멀티모달 문서 처리** — 이미지 위주 PDF는 Vision LLM으로 페이지를 읽어 설명+스크린샷 첨부, PPTX 슬라이드 추출, Notion DB 연동까지. 답변 본문 **사이사이에 관련 화면을 인라인 삽입**.



**지식 소스 자동 동기화** — Notion 데이터베이스를 last\_edited\_time 기반 증분 동기화(변경 페이지만 재처리). 만료되는 이미지 URL은 자체 서버로 재호스팅.



**운영형 관리자 콘솔** — 문서 업로드/벡터화 파이프라인, 대화 히스토리, 미답변·수정요청 처리, 응답 규칙·검색어 매핑, LLM-as-Judge 평가 하베스트.



**부서별 사용자 분석** — 외부 인사 DB(MySQL)에서 직원 명단을 읽기전용 동기화하고, 로그인 ID 기준으로 질문을 귀속해 사용 현황을 시각화.




**POS 데이터 Tool Calling** — 자연어 질의를 함수 호출로 변환해 운영 DB를 조회(SELECT 전용·실행시간 제한 가드).

PRODUCT

실제 화면

사용자용 **스트리밍 챗봇**과 운영자용 **관리자 콘솔**을 하나의 시스템으로 구현했습니다. 검색·생성뿐 아니라 **운영과 분석**까지 닿아 있는 제품입니다.



 **근거 기반 답변 + 관련 화면**

- ✓ 질문 유형에 맞춘 **구조화 답변** (조치 안내 · 상세 절차)
- ✓ 절차 단계 바로 옆에 **관련 화면을 인라인** 으로 삽입
- ✓ 답변 하단에 **관련 문서 출처** (Notion · PDF) 링크 노출
- ✓ 로그인 사용자·부서 표시 · **SSE 실시간 스트리밍**

## AT 관리자 콘솔

문서 업로드

검색어 맵핑

응답 규칙

대화 조회

통계

사용자 통계

평가

## 사용자 통계

명단 동기화

질문 귀속은 로그인 ID 기준입니다. 로그인 후 질문한 사용자만 표시됩니다.

## 사용자별 질문수 (8명)

|   |     |       |    |
|---|-----|-------|----|
| 1 | 서수민 | 고객지원부 | 42 |
| 2 | 홍지원 | 고객지원부 | 31 |
| 3 | 김도윤 | 고객지원부 | 23 |
| 4 | 이서연 | 법인사업부 | 18 |
| 5 | 박준호 | 고객지원부 | 14 |
| 6 | 최민재 | 기술지원팀 | 9  |
| 7 | 정하윤 | 고객지원부 | 6  |
| 8 | 강시우 | 기타    | 3  |

## 카테고리별 이용 현황

|    |            |
|----|------------|
| 약국 | 질문 78 · 6명 |
| 공통 | 질문 36 · 5명 |
| 학원 | 질문 22 · 3명 |
| 병원 | 질문 12 · 2명 |

**사용자 통계** — 외부 인사 DB 명단을 읽기전용 동기화하고, 로그인 ID로 질문을 귀속해 사용자별 질문수·카테고리별 이용을 시각화.

## AT 관리자 콘솔

문서 업로드

검색어 맵핑

응답 규칙

대화 조회

통계

사용자 통계

평가

## 문서 관리

업로드 → 텍스트화 → 검수 → 벡터화 파이프라인. PDF·PPTX·Notion 다중 소스 자동 처리.

파일 업로드 텍스트 입력 대화 추출 노션 동기화

| 파일명                     | 카테고리 | 등록/수정자     | 텍스트화 | 검수 | 벡터화 | 체크 |
|-------------------------|------|------------|------|----|-----|----|
| NOTION ESL 관리 )태그 관리    | 약국   | notion     | 변환완료 | 승인 | 벡터화 | 4  |
| PPTX 학원 단말기 연동 매뉴얼.pptx | 학원   | 김명희<br>박준호 | 변환완료 | 승인 | 벡터화 | 21 |
| PDF 약국 POS 설치 매뉴얼.pdf   | 약국   | 김명희        | 변환완료 | 승인 | 벡터화 | 36 |
| TEXT 키오스크 비밀번호 안내       | 공통   | 서수민        | 직접입력 | 승인 | 벡터화 | 1  |

**문서 파이프라인** — PDF · PPTX · Notion 다중 소스를 업로드 → 텍스트화 → 검수 → 벡터화로 자동 처리하고, 등록자·최종수정자까지 추적.

# 검색 · 생성 파이프라인



## ENGINEERING HIGHLIGHTS

# 문제 → 해결로 보는 기술 역량

### PERFORMANCE

#### 리랭커 도입 후 느려진 응답속도 최적화

##### 문제

긴 비전 설명 문서가 Cross-encoder 입력으로 들어가며 검색 단계가 수십 초까지 지연. 후보 수를 줄이면 품질 저하 우려.

##### 해결

단계별 소요시간 로깅으로 병목을 리랭커 입력 길이로 특정. 후보 수·리랭커는 유지하고

##### 입력 텍스트만 절단

. 평가 하베스트로 품질 동일함을 검증.

→ 후보 20개·리랭커 유지하면서 검색 단계 약 3배 가속, 답변 품질 동등

## MULTIMODAL

### 링크와 이미지를 동시에, 그리고 본문 사이사이에

#### 문제

벡터 1건당 출처가 하나라 "이미지 표시 ↔ 문서 링크"가 양자택 일. 이미지가 답변 맨 끝에 뭉쳐 맥락과 분리.

#### 해결

메타데이터에 재호스팅 이미지 URL을 함께 실어

#### 링크+이미지 동시 노출

. LLM이 토큰([그림N])을 배치하게 유도해 본문 해당 단계에

#### 인라인 렌더링

.

→ 절차형 매뉴얼에서 단계별 화면이 설명 바로 옆에 표시

## DATA SYNC

### 만료되는 외부 자산과 "로그인 안 한 사람" 문제

#### 문제

Notion 이미지 URL은 시간이 지나면 만료. 사용 통계는 로그인한 사람만 보여 전체 모수를 알 수 없음.

#### 해결

인제스트 시 이미지를 자체 서버로

#### 재호스팅

, 변경분만 증분 동기화. 인사 DB에서 직원 명단을

#### 읽기전용 복제

해 미사용자까지 포함한 분모를 확보.

→ 항상 표시되는 이미지 + 전사 기준의 신뢰할 수 있는 사용 분석

## TECH STACK

# 기술 스택

### AI / RAG

- ▶ LangGraph · LangChain
- ▶ pgvector (HNSW)
- ▶ Cross-encoder 리랭커
- ▶ multilingual-e5 임베딩
- ▶ OpenAI gpt-4o-mini (생성·Vision)

### Backend

- ▶ Python (http.server, SSE)
- ▶ PostgreSQL · 하이브리드 검색
- ▶ PyMuPDF · python-pptx
- ▶ Tool Calling (함수 호출)
- ▶ AES128 인증 연동

## Frontend

- ▶ Vanilla JS SPA(관리자)
- ▶ 스트리밍 챗 UI
- ▶ 마크다운·인라인 이미지 렌더
- ▶ CSS 데이터 시각화(도넛·막대)

## Data / Infra

- ▶ PostgreSQL · MySQL
- ▶ Notion API 연동
- ▶ Linux · systemd
- ▶ 증분 동기화 · 백그라운드 잡

## CONTACT

**김명희** · Fullstack AI Engineer

올댓페이 AX팀 · [pianovirus@naver.com](mailto:pianovirus@naver.com)