

● Production · 사내 운영 중

사내 지식 기반 RAG AI 어시스턴트 설계부터 운영까지 풀스택 단독 개발

PostgreSQL · pgvector 하이브리드 검색과 Cross-encoder 리랭킹, 검색 실패를 스스로 보정하는 자기교정(Corrective RAG) 루프, 멀티모달 문서 처리(PDF·PPTX·Notion)를 결합해 5개 업종 사내 지식을 답변하는 RAG 챗봇. 검색·생성 파이프라인부터 관리자 콘솔, **골든셋 기반 자동 평가**, 사용자 분석, 배포·운영까지 직접 구현했습니다.

5개 업종

약국·병의원·학원·한의원·공통

하이브리드

벡터·키워드·구문·리랭커

멀티모달

PDF 비전·PPTX·Notion

자기교정

CRAG·검색 실패 자동 복구

Tool Calling

자연어 → POS DB 조회

End-to-End

검색·생성·관리자·분석·배포

OVERVIEW

한눈에 보는 프로젝트

사내 직원이 업종별 매뉴얼·운영 지식을 자연어로 질문하면, 근거 문서를 검색해 출처와 함께 답변하는 사내 전용 AI 어시스턴트입니다. "그렇듯하지만 틀린 답변"을 막기 위해 **근거 기반 응답·관련 문서 노출·미답변 추적**을 핵심 원칙으로 설계했고, 실제 운영을 위한 관리자 콘솔과 사용자 분석까지 하나의 시스템으로 구축했습니다.

역할

기획·아키텍처·백엔드·프론트엔드·DB·배포까지 **단독 풀스택 개발**. RAG 파이프라인 설계와 검색 품질·응답속도 최적화를 주도.



문제

분산된 업종별 매뉴얼(PDF·PPT·Notion)을 직원이 빠르게 찾기 어려움. 일반 LLM은 사내 사실을 모르고 환각 위험.



해결

사내 문서를 벡터화한 하이브리드 RAG + 리랭킹으로 근거 기반 답변. 출처 링크·관련 화면을 함께 제공.

FEATURES

핵심 기능



하이브리드 검색 + 리랭킹 — pgvector 임베딩 검색 · 키워드(tsvector) · 구문 매칭 점수를 결합하고, bge-reranker Cross-encoder로 재정렬해 정확도 향상.



LangGraph 자기교정 파이프라인 — 질문 분류 → 멀티턴 맥락 기반 질의 재작성("그거/아까" 해소) → 검색 → 근거 기반 프롬프트를 그래프로 구성. **관련 결과가 없으면 카테고리를 완화해 재검색하는 Corrective RAG 루프, 모호한 질문은 되묻고 (clarification),** 여러 업종에 걸친 답은 **업종별로 그룹화**해 미응답을 최소화.



멀티모달 문서 처리 — 이미지 위주 PDF는 Vision LLM으로 페이지를 읽어 설명+스크린샷 첨부, PPTX 슬라이드 추출, Notion DB 연동까지. 답변 본문 **사이사이에 관련 화면을 인라인 삽입.**



지식 소스 자동 동기화 — Notion 데이터베이스를 last_edited_time 기반 증분 동기화(변경 페이지만 재처리). 만료되는 이미지 URL은 자체 서버로 재호스팅.



운영형 관리자 콘솔 — 문서 업로드/벡터화 파이프라인, 대화 히스토리, 미답변·수정요청 처리, 응답 규칙·검색어 매핑까지 운영에 필요한 도구를 한 화면에.



골든셋 자동 평가 시스템 — 업종별 정답 기준을 담은 골든셋을 **LLM-as-Judge**로 자동 채점(정답/부분/오답). 검색·프롬프트를 바꿀 때마다 **회귀 테스트**로 품질 저하를 사전 차단.



부서별 사용자 분석 — 외부 인사 DB(MySQL)에서 직원 명단을 읽기전용 동기화하고, 로그인 ID 기준으로 질문을 귀속해 사용 현황을 시각화.



POS 데이터 Tool Calling — 자연어 질의를 함수 호출로 변환해 운영 DB를 조회(SELECT 전용·실행시간 제한 가드).




사내 계정 인증 — 레거시 인증 API(AES128-CBC) 동등 구현, 5시간 슬라이딩 세션, 슈퍼관리자 권한 게이팅.

PRODUCT

실제 화면

사용자용 **스트리밍 챗봇**과 운영자용 **관리자 콘솔**을 하나의 시스템으로 구현했습니다. 검색·생성뿐 아니라 **운영과 분석**까지 닿아 있는 제품입니다.



💬 근거 기반 답변 + 관련 화면

- ✓ 질문 유형에 맞춘 **구조화 답변** (조치 안내·상세 절차)
- ✓ 절차 단계 바로 옆에 **관련 화면을 인라인** 으로 삽입
- ✓ 답변 하단에 **관련 문서 출처** (Notion·PDF) 링크 노출
- ✓ 로그인 사용자·부서 표시 · **SSE 실시간 스트리밍**

AT 관리자 콘솔

문서 업로드

검색어 맵핑

응답 규칙

대화 조회

통계

사용자 통계

평가

사용자 통계

명단 동기화

질문 귀속은 로그인 ID 기준입니다. 로그인 후 질문한 사용자만 표시됩니다.

사용자별 질문수 (8명)

1	서수민	고객지원부	42
2	홍지원	고객지원부	31
3	김도윤	고객지원부	23
4	이서연	법인사업부	18
5	박준호	고객지원부	14
6	최민재	기술지원팀	9
7	정하윤	고객지원부	6
8	강시우	기타	3

카테고리별 이용 현황

약국	질문 78 · 6명
공통	질문 36 · 5명
학원	질문 22 · 3명
병원	질문 12 · 2명

사용자 통계 — 외부 인사 DB 명단을 읽기전용 동기화하고, 로그인 ID로 질문을 귀속해 사용자별 질문수·카테고리별 이용을 시각화.

AT 관리자 콘솔

문서 업로드

검색어 맵핑

응답 규칙

대화 조회

통계

사용자 통계

평가

문서 관리


업로드 → 텍스트화 → 검수 → 벡터화 파이프라인. PDF·PPTX·Notion 다중 소스 자동 처리.

파일 업로드 텍스트 입력 대화 추출 노션 동기화

파일명	카테고리	등록/수정자	텍스트화	검수	벡터화	체크
NOTION ESL 관리)태그 관리	약국	notion	변환완료	승인	벡터화	4
PPTX 학원 단말기 연동 매뉴얼.pptx	학원	김명희 박준호	변환완료	승인	벡터화	21
PDF 약국 POS 설치 매뉴얼.pdf	약국	김명희	변환완료	승인	벡터화	36
TEXT 키오스크 비밀번호 안내	공통	서수민	직접입력	승인	벡터화	1

문서 파이프라인 — PDF · PPTX · Notion 다중 소스를 업로드 → 텍스트화 → 검수 → 벡터화로 자동 처리하고, 등록자·최종수정자까지 추적.

검색 · 생성 파이프라인



ENGINEERING HIGHLIGHTS

문제 → 해결로 보는 기술 역량

SELF-CORRECTING RAG

검색 실패를 스스로 복구하는 CRAG 루프

문제

한 번 검색해 결과가 없으면 "정보 없음"으로 끝남. 특히 사용자가 업종(카테고리)을 잘못 고르면 답이 있는데도 못 찾음.

해결

LangGraph

조건부 엣지로 검색→재작성→검색 루프(cyclic graph)

를 구성해, 결과가 없거나

관련도가 낮으면(리랭커 점수 임계)

카테고리 조건을 완화해 재검색(Corrective RAG).

관련 결과가 있으면 재시도하지 않아 기존 검색은 무영향

, 최대 재시도로 무한루프 차단 · 환경변수 킬스위치 + 골든셋 회귀 검증으로 무종단 적용.

→ 업종을 잘못 골라 무관한 결과만 잡혀도 자동 복구, 되던 검색은 100% 동일

"감"이 아니라 정량 평가로 — 골든셋 회귀 테스트

문제

검색·프롬프트를 한 번 바꾸면 다른 질문이 조용히 깨질 수 있음.
"그렇듯하지만 틀린 답"을 사람이 매번 일일이 확인하는 건 불가능.

해결

업종별

골든셋(질문 + 정답 기준)

을 구축하고

LLM-as-Judge

로 정답/부분/오답을 자동 채점. 모든 검색·생성 변경을

골든셋 회귀로 검증

한 뒤에만 무중단 적용(킬스위치 병행). 실패는 데이터 오타·검색
누락·비결정성·기준 과엄격으로

유형 분류해 처방

→ 한 곳을 고치다 다른 곳이 깨지는 회귀를 배포 전 포착 (예: 긴 문서 청크 검색 개선이 표 조회를 깨뜨리는 트레이드오프를 사전 발견·차단)

모호하면 되묻고, 답은 업종별로, 근거에만 충실하게

문제

"결제"처럼 짧고 모호한 질문엔 엉뚱한 결과. 카테고리틀 잘못 골라도 답이 있는데 못 찾음. 근거가 없을 때 LLM이 일반 상식으로 그럴듯하게 지어냄(환각).

해결

① 너무 짧은 질문은 폴스캔 전에

정중히 되묻기(clarification)

· ② 카테고리 미스매치는 전체 검색으로 복구하되 여러 업종에 답이 있으면

📁 **업종별로 나눠 답변**

· ③ 답변 프롬프트에서

추측 섹션을 제거

해 데이터 근거만 답하게(Faithfulness). 모두 킬스위치 + 골든셋 회귀로 검증.

→ 미답변·환각을 줄이고, 사용자가 카테고리를 완벽히 고르지 않아도 답을 찾아줌

PERFORMANCE

리랭커 도입 후 느려진 응답속도 최적화

문제

긴 비전 설명 문서가 Cross-encoder 입력으로 들어가며 검색 단계가 수십 초까지 지연. 후보 수를 줄이면 품질 저하 우려.

해결

단계별 소요시간 로깅으로 병목을 리랭커 입력 길이로 특정. 후보 수·리랭커는 유지하고

입력 텍스트만 절단

. 평가 하베스트로 품질 동일함을 검증.

→ 후보 20개·리랭커 유지하면서 검색 단계 약 3배 가속, 답변 품질 동등

MULTIMODAL

링크와 이미지를 동시에, 그리고 본문 사이사이에

문제

벡터 1건당 출처가 하나라 "이미지 표시 ↔ 문서 링크"가 양자택일. 이미지가 답변 맨 끝에 뭉쳐 맥락과 분리.

해결

메타데이터에 재호스팅 이미지 URL을 함께 실어

링크+이미지 동시 노출

. LLM이 토큰([그림N])을 배치하게 유도해 본문 해당 단계에 인라인 렌더링

→ 절차형 매뉴얼에서 단계별 화면이 설명 바로 옆에 표시

DATA SYNC

만료되는 외부 자산과 "로그인 안 한 사람" 문제

문제

Notion 이미지 URL은 시간이 지나면 만료. 사용 통계는 로그인한 사람만 보여 전체 모수를 알 수 없음.

해결

인제스트 시 이미지를 자체 서버로

재호스팅

, 변경분만 증분 동기화. 인사 DB에서 직원 명단을

읽기전용 복제

해 미사용자까지 포함한 분모를 확보.

→ 항상 표시되는 이미지 + 전사 기준의 신뢰할 수 있는 사용 분석

기술 스택

AI / RAG

- ▶ LangGraph · LangChain
- ▶ pgvector (HNSW)
- ▶ Cross-encoder 리랭커
- ▶ multilingual-e5 임베딩
- ▶ OpenAI gpt-4o-mini (생성·Vision)

Frontend

- ▶ Vanilla JS SPA(관리자)
- ▶ 스트리밍 챗 UI
- ▶ 마크다운·인라인 이미지 렌더
- ▶ CSS 데이터 시각화(도넛·막대)

Backend

- ▶ Python (http.server, SSE)
- ▶ PostgreSQL · 하이브리드 검색
- ▶ PyMuPDF · python-pptx
- ▶ Tool Calling (함수 호출)
- ▶ AES128 인증 연동

Data / Infra

- ▶ PostgreSQL · MySQL
- ▶ Notion API 연동
- ▶ Linux · systemd
- ▶ 증분 동기화 · 백그라운드 잡

CONTACT

김명희 · Fullstack AI Engineer

올댓페이 AX팀 · pianovirus@naver.com