

● Production · 사내 운영 중

사내 지식 기반 RAG AI 어시스턴트 설계부터 운영까지 풀스택 단독 개발

PostgreSQL · pgvector 하이브리드 검색과 Cross-encoder 리랭킹, 멀티모달 문서 처리 (PDF·PPTX·Notion)를 결합해 5개 업종 사내 지식을 답변하는 RAG 챗봇. 검색·생성 파이프라인부터 관리자 콘솔, 사용자 분석, 배포·운영까지 직접 구현했습니다.

5개 업종

약국·병의원·학원·한의원·공
통

하이브리드

벡터 + 키워드 + 구문 + 리
랭커

멀티모달

PDF 비전 · PPTX · Notion

End-to- End

검색·생성·관리자·분석·배포

OVERVIEW

한눈에 보는 프로젝트

사내 직원이 업종별 매뉴얼·운영 지식을 자연어로 질문하면, 근거 문서를 검색해 출처와 함께 답변하는 사내 전용 AI 어시스턴트입니다. "그렇듯하지만 틀린 답변"을 막기 위해 **근거 기반 응답·관련 문서 노출·미답변 추적**을 핵심 원칙으로 설계했고, 실제 운영을 위한 관리자 콘솔과 사용자 분석까지 하나의 시스템으로 구축했습니다.



역할

기획·아키텍처·백엔드·프론트엔드·DB·배포까지 **단독 풀스택 개발**. RAG 파이프라인 설계와 검색 품질·응답속도 최적화를 주도.



문제

분산된 업종별 매뉴얼(PDF·PPT·Notion)을 직원이 빠르게 찾기 어려움. 일반 LLM은 사내 사실을 모르고 환각 위험.



해결

사내 문서를 벡터화한 하이브리드 RAG + 리랭킹으로 근거 기반 답변. 출처 링크·관련 화면을 함께 제공.

FEATURES

핵심 기능



하이브리드 검색 + 리랭킹 — pgvector 임베딩 검색 · 키워드(tsvector) · 구문 매칭 점수를 결합하고, bge-reranker Cross-encoder로 재정렬해 정확도 향상.



LangGraph 대화 파이프라인 — 질문 분류 → 멀티턴 맥락 기반 질의 재작성("그거/아까" 해소) → 검색 → 근거 기반 프롬프트 생성을 그래프로 구성.



멀티모달 문서 처리 — 이미지 위주 PDF는 Vision LLM으로 페이지를 읽어 설명+스크린샷 첨부, PPTX 슬라이드 추출, Notion DB 연동까지. 답변 본문 **사이사이에 관련 화면을 인라인 삽입**.



지식 소스 자동 동기화 — Notion 데이터베이스를 last_edited_time 기반 증분 동기화(변경 페이지만 재처리). 만료되는 이미지 URL은 자체 서버로 재호스팅.



운영형 관리자 콘솔 — 문서 업로드/벡터화 파이프라인, 대화 히스토리, 미답변·수정요청 처리, 응답 규칙·검색어 매핑, LLM-as-Judge 평가 하베스트.



부서별 사용자 분석 — 외부 인사 DB(MySQL)에서 직원 명단을 읽기전용 동기화하고, 로그인 ID 기준으로 질문을 귀속해 사용 현황을 시각화.




POS 데이터 Tool Calling — 자연어 질의를 함수 호출로 변환해 운영 DB를 조회(SELECT 전용·실행시간 제한 가드).

PRODUCT

실제 화면

사용자용 **스트리밍 챗봇**과 운영자용 **관리자 콘솔**을 하나의 시스템으로 구현했습니다. 검색·생성뿐 아니라 **운영과 분석**까지 닿아 있는 제품입니다.



 근거 기반 답변 + 관련 화면

- ✓ 질문 유형에 맞춘 **구조화 답변** (조치 안내 · 상세 절차)
- ✓ 절차 단계 바로 옆에 **관련 화면을 인라인** 으로 삽입
- ✓ 답변 하단에 **관련 문서 출처** (Notion · PDF) 링크 노출
- ✓ 로그인 사용자·부서 표시 · **SSE 실시간 스트리밍**

AT 관리자 콘솔

문서 업로드

검색어 맵핑

응답 규칙

대화 조회

통계

사용자 통계

평가

사용자 통계

명단 동기화

질문 귀속은 로그인 ID 기준입니다. 로그인 후 질문한 사용자만 표시됩니다.

사용자별 질문수 (8명)

1	서수민	고객지원부	42
2	홍지원	고객지원부	31
3	김도윤	고객지원부	23
4	이서연	법인사업부	18
5	박준호	고객지원부	14
6	최민재	기술지원팀	9
7	정하윤	고객지원부	6
8	강시우	기타	3

카테고리별 이용 현황

약국	질문 78 · 6명
공통	질문 36 · 5명
학원	질문 22 · 3명
병원원	질문 12 · 2명

사용자 통계 — 외부 인사 DB 명단을 읽기전용 동기화하고, 로그인 ID로 질문을 귀속해 사용자별 질문수·카테고리별 이용을 시각화.

AT 관리자 콘솔

문서 업로드

검색어 맵핑

응답 규칙

대화 조회

통계

사용자 통계

평가

문서 관리

업로드 → 텍스트화 → 검수 → 벡터화 파이프라인. PDF·PPTX·Notion 다중 소스 자동 처리.

파일 업로드 텍스트 입력 대화 추출 노션 동기화

파일명	카테고리	등록/수정자	텍스트화	검수	벡터화	체크
NOTION ESL 관리)태그 관리	약국	notion	변환완료	승인	벡터화	4
PPTX 학원 단말기 연동 매뉴얼.pptx	학원	김명희 박준호	변환완료	승인	벡터화	21
PDF 약국 POS 설치 매뉴얼.pdf	약국	김명희	변환완료	승인	벡터화	36
TEXT 키오스크 비밀번호 안내	공통	서수민	직접입력	승인	벡터화	1

문서 파이프라인 — PDF · PPTX · Notion 다중 소스를 업로드 → 텍스트화 → 검수 → 벡터화로 자동 처리하고, 등록자·최종수정자까지 추적.

검색 · 생성 파이프라인



ENGINEERING HIGHLIGHTS

문제 → 해결로 보는 기술 역량

PERFORMANCE

리랭커 도입 후 느려진 응답속도 최적화

문제

긴 비전 설명 문서가 Cross-encoder 입력으로 들어가며 검색 단계가 수십 초까지 지연. 후보 수를 줄이면 품질 저하 우려.

해결

단계별 소요시간 로깅으로 병목을 리랭커 입력 길이로 특정. 후보 수·리랭커는 유지하고

입력 텍스트만 절단

. 평가 하베스트로 품질 동일함을 검증.

→ 후보 20개·리랭커 유지하면서 검색 단계 약 3배 가속, 답변 품질 동등

MULTIMODAL

링크와 이미지를 동시에, 그리고 본문 사이사이에

문제

벡터 1건당 출처가 하나라 "이미지 표시 ↔ 문서 링크"가 양자택일. 이미지가 답변 맨 끝에 뭉쳐 맥락과 분리.

해결

메타데이터에 재호스팅 이미지 URL을 함께 실어

링크+이미지 동시 노출

. LLM이 토큰([그림N])을 배치하게 유도해 본문 해당 단계에

인라인 렌더링

.

→ 절차형 매뉴얼에서 단계별 화면이 설명 바로 옆에 표시

DATA SYNC

만료되는 외부 자산과 "로그인 안 한 사람" 문제

문제

Notion 이미지 URL은 시간이 지나면 만료. 사용 통계는 로그인한 사람만 보여 전체 모수를 알 수 없음.

해결

인제스트 시 이미지를 자체 서버로

재호스팅

, 변경분만 증분 동기화. 인사 DB에서 직원 명단을

읽기전용 복제

해 미사용자까지 포함한 분모를 확보.

→ 항상 표시되는 이미지 + 전사 기준의 신뢰할 수 있는 사용 분석

TECH STACK

기술 스택

AI / RAG

- ▶ LangGraph · LangChain
- ▶ pgvector (HNSW)
- ▶ Cross-encoder 리랭커
- ▶ multilingual-e5 임베딩
- ▶ OpenAI gpt-4o-mini (생성·Vision)

Backend

- ▶ Python (http.server, SSE)
- ▶ PostgreSQL · 하이브리드 검색
- ▶ PyMuPDF · python-pptx
- ▶ Tool Calling (함수 호출)
- ▶ AES128 인증 연동

Frontend

- ▶ Vanilla JS SPA(관리자)
- ▶ 스트리밍 챗 UI
- ▶ 마크다운·인라인 이미지 렌더
- ▶ CSS 데이터 시각화(도넛·막대)

Data / Infra

- ▶ PostgreSQL · MySQL
- ▶ Notion API 연동
- ▶ Linux · systemd
- ▶ 증분 동기화 · 백그라운드 잡

CONTACT

김명희 · Fullstack AI Engineer

올댓페이 AX팀 · pianovirus@naver.com



LIVE DEMO · 실제 체험용

처방전 입력 → AI 추천 결과까지 직접 체험해보기

http://139.150.72.14:7705/mobile



● HEALTHCARE · AI · FULLSTACK

약국 처방전 기반 AI 영양제 추천 시스템

식품의약품안전처·PubMed·FDA 공공 데이터를 통합해 환자별 맞춤 영양제·생활가이드를 자동 추천하는 풀스택 헬스케어 AI 플랫폼. 백엔드 / 데이터 파이프라인 / LLM 검증 / 멀티 디바이스 UI 전 영역 단독 개발.

Python · FastAPI

MySQL · PooledDB

LLM Fallback Chain

Alpine.js · Tailwind

공공 API 7종

구조 예시 · 실 화면 ↑ 데모

처방전 20260601000005

tid 2222555



정현우 sid=2382
(주)올댓페이

금액
8,560원

KCD

M159

M6283

K29

🔥 AI 추천 영양소



칼슘

근육·신경



비타민 D

뼈 건강



마그네슘

근육 이완



오메가-3

항염



커큐민

항염증



단백질

근력

🌐 태블릿

📱 포스

♥ 네이버

IMPACT IN NUMBERS

45,244

건강기능식품 마스터
식약처 OpenAPI 매일 자동 수집

43,179

의약품 허가정보
식약처 실시간 OpenAPI

812,128

DUR 안전성 룰
비용금기·임부금기·노인주의 등

614

영양소 마스터 (정규화 후)
741 → 127개 중복 정리

OVERVIEW

한 줄로 정리하면

약사가 처방전을 받았을 때, **환자의 질병코드(KCD)·처방약·연령**을 종합 분석해 "**이 환자에게 이 영양제가 왜 필요한지**" AI가 근거와 함께 즉시 추천하고, 그 결과를 **태블릿·POS·네이버 커넥트** 등 멀티 디바이스로 환자에게 보여주는 풀스택 시스템입니다.

단순 LLM Wrapper가 아니라, **PubMed 논문·식약처 DUR·미국 FDA**라는 공공 의료 데이터를 직접 수집·정규화하고, LLM의 잘못된 답변(DOI 환각)을 4단계로 교차 검증해 **근거 없는 추천을 자동으로 차단**하는 신뢰성 중심 설계가 핵심입니다.

시스템 아키텍처

LAYER 1

데이터 수집·정규화

- 식약처 의약품 허가 OpenAPI (43k건/일)
- 식품안전나라 건기식 OpenAPI (45k건/일)
- 식약처 DUR (비용/임부/노인 81만 룰)
- PubMed 의학논문 검색
- 미국 FDA Drug Label
- 자동 fuzzy 매칭 (영양소 ↔ 제품)

LAYER 2

AI 추천 & 검증

- 통합 advisor: KCD·ATC 라우팅
- **LLM Fallback Chain** (Gemini → OpenAI → Grok)
- **4단계 검증**: PubMed·KFDA·FDA·LLM 교차
- DOI 환각 차단 (논문 3-way verify)
- 병용금기 자동 차단 (DUR 81만 룰)
- 5분 TTL 결과 캐시 (LLM 호출 최소화)

LAYER 3

API & 멀티 디바이스 UI

- FastAPI REST endpoints (15+)
- **fire-and-forget** background task (2300건 batch 처리)
- 어드민 SPA (Alpine.js + Tailwind)
- 태블릿 / POS 간편 / 네이버 커넥트 웹뷰
- 외부 SCM 양방향 통신 (insert/조회)
- 처방전 호출 이력 + 결과 트래킹

HIGHLIGHTS

기술적 의사결정 하이라이트



RELIABILITY

DOI 환각 4단계 검증

LLM 이 만들어낸 가짜 논문 DOI 가 환자에게 노출되지 않도록, PubMed 검색 → 논문 본문 fetch → 3-way LLM 교차 평가 → 다수결 통과만 노출의 검증 파이프라인 구축. 미통과 항목은 자동 검토 큐로 분리.



SCALE

2,300건 fire-and-forget Batch

POS 가 미매핑 상품 2,300+건을 한 번에 보내도 클라이언트 timeout 없이 즉시 ack 후 백그라운드 threadpool 에서 fuzzy 매칭·외부 SCM forward 처리. 500건씩 batch wrap + row-level 실패 추적 + 완료 시 DB 결과 반영.



SAFETY

비용금지 자동 차단

식약처 DUR 81만건 룰 (비용금지·임부금지·노인주의·용량주의·효능군 중복) 을 환자 처방약과 자동 비교, 위험 조합 영양소·생활가이드는 추천에서 자동 제외. 약사가 받는 결과는 이미 1차 안전성 필터링 완료 상태.



RESILIENCE

LLM Fallback Chain

Gemini 429(quota) → OpenAI → Grok 순으로 자동 전환. 5분 TTL 결과 캐시로 분리형 endpoint(info/nutrients/guides/contras) 가 같은 처방을 4번 호출해도 LLM 1회만 호출. 비용·지연 최적화.



UX

멀티 디바이스 통합

같은 추천 결과를 태블릿 / POS 간편 / 네이버 커넥트 / 모바일 wizard 4개 디바이스에 각각 맞는 레이아웃으로 렌더링. POS 동작에 따라 화면을 실시간 push 전환.

DATA SOURCES

통합한 공공 의료 데이터 출처

식품의약품안전처

의약품 제품 허가정보 OpenAPI · 의약품 안전사용서비스(DUR) · e약품요

식품안전나라

건강기능식품 인허가 OpenAPI (식약처 운영)

PubMed

미국 국립의학도서관 의학 논문 DB · DOI 검증

미국 FDA

Drug Label · 효능/경고/상호작용

보건복지부

KCD-7 질병분류코드

심평원

ATC 매핑 · 보험 EDI 코드

약국 POS

실시간 보유 재고 · 약사 직접 입력 코멘트

네이버 커넥트

결제예정 · 서비스 선택 화면 디바이스 연동

MY ROLE

담당 역할 (전 영역 단독)



시스템 아키텍처 설계

데이터 수집 → 정규화 → 검증 → 추천 → 멀티 디바이스 전체 흐름



외부 API 통합

7개 공공 데이터 OpenAPI / 인증·페이지네이션·재시도·rate limit



LLM 통합 · 검증 시스템

Multi-provider fallback, 4단계 환각 차단, 결과 캐시



DB 설계 + ETL 파이프라인

MySQL 50+ 테이블 / fuzzy 매칭 / 자동 중복 정리



어드민 SPA + 멀티 디바이스 UI

Alpine.js + Tailwind, 30+ 페이지, 처방전 분석 대시보드



DevOps · 배포 자동화

SSH 자동 배포 / 백업·롤백 / 무중단 재기동

CONTACT

김명희 · Fullstack AI Engineer

울דת페이 AX팀 · pianovirus@naver.com

본 포트폴리오는 실제 운영 중인

울דת페이 AI Pharm 시스템의 기술적 의사결정과 성과를 정리한 자료입니다.